MÔN HỌC: KHAI PHÁ DỮ LIỆU (ITEC3417) — ĐỒ ÁN MÔN HỌC / BÀI TẬP LỚN

BÀI TẬP LỚN: THU THẬP VÀ KHAI PHÁ DỮ LIỆU TUYỂN DỤNG THỰC TẾ TRONG NGÀNH CNTT & KHOA HỌC DỮ LIỆU TẠI VIỆT NAM

Hình thức: Làm việc theo nhóm (3 - 5 sinh viên/nhóm) **Báo cáo:** Thuyết trình + Vấn đáp phản biện tại buổi cuối

Sản phẩm nộp: Mã nguồn Crawler + Bộ dữ liệu Thô & Sạch + Notebook KDD + Báo cáo tổng kết (PDF)

1. MỤC TIÊU VÀ Ý NGHĨA THỰC TIỄN CỦA ĐỒ ÁN

Bài tập lớn là cơ hội để sinh viên đóng vai trò một **Data Mining Engineer** thực hiện trọn vẹn quy trình KDD (Knowledge Discovery in Databases) từ con số 0 trên nguồn dữ liệu sống thực tế tại thị trường lao động Việt Nam. Thay vì thao tác trên các bộ dữ liệu đồ chơi hoặc tệp mẫu có sẵn, các nhóm phải tự động hóa việc thu thập dữ liệu tuyển dụng việc làm CNTT, giải quyết bài toán tiền xử lý văn bản phức tạp, trích xuất kỹ năng, gom cụm phân khúc thị trường và dự báo mức lương/yêu cầu công việc.

2. GIAI ĐOẠN 1: XÁC ĐỊNH TỪ KHÓA ĐỊNH VỊ & TỰ VIẾT CÔNG CỤ THU THẬP DỮ LIỆU (WEB SCRAPING)

Mỗi nhóm bắt buộc phải tự xây dựng công cụ cào dữ liệu (Web Scraper / Crawler) độc lập, không dùng các dịch vụ cào dữ liệu trả phí bên thứ ba:

- **Xác định tập từ khóa mục tiêu:** Nhóm chọn một phân khúc cụ thể trong ngành CNTT (ví dụ: *Data Science / Data Analytics / AI / Machine Learning, Backend Developer, Frontend Developer, DevOps / Cloud, Software Testing, Cybersecurity*). Từ khóa phải bao gồm cả tên vị trí, kỹ năng cốt lõi (ví dụ: `Python`, `SQL`, `PowerBI`, `PyTorch`, `Spark`).
- **Nguồn thu thập dữ liệu (Target Platforms):** Sinh viên lựa chọn thu thập dữ liệu từ ít nhất 01 (ưu tiên kết hợp từ 02) nền tảng tuyển dụng lớn tại Việt Nam:
  - Các trang tuyển dụng chuyên ngành: **ITviec, VietnamWorks, TopCV, CareerBuilder/VietNamNet Jobs, Glints**.
  - Mạng xã hội nghề nghiệp: **LinkedIn Jobs** hoặc các bài đăng tuyển dụng công khai trên các cộng đồng tuyển dụng IT uy tín trên **Facebook**.
- **Công nghệ khuyến nghị:** Sử dụng các thư viện Python chuyên dụng: `requests`, `BeautifulSoup4`, `Selenium`, hoặc `Playwright`. Công cụ phải lưu lại đầy đủ logic phân trang (Pagination), vượt qua các cơ chế tải động (Infinite Scroll/AJAX), và thiết lập thời gian chờ ngẫu nhiên (`delay/sleep`) để tuân thủ đạo đức thu thập dữ liệu (Robots.txt etiquette).
- **Đầu ra bắt buộc của Giai đoạn 1:** Một tệp dữ liệu thô chưa qua làm sạch (`raw_jobs_data.csv` hoặc `.json`) với quy mô **tối thiểu từ 800 đến 1.500+ tin tuyển dụng**. Tệp thô phải giữ nguyên cấu trúc văn bản gốc, bao gồm: Tiêu đề công việc, Tên công ty, Địa điểm làm việc, Mức lương gốc (chưa chuẩn hóa), Kinh nghiệm yêu cầu, Mô tả công việc (Job Description - JD) và Quyền lợi/Yêu cầu chi tiết.

> **Yêu cầu trung thực học thuật về dữ liệu:** Mỗi nhóm bắt buộc phải lưu kèm tệp mã nguồn cào dữ liệu (`scraper.py` hoặc `crawler.ipynb`) có ghi rõ dấu vết thời gian thu thập (Timestamp). Trong buổi báo cáo cuối kỳ, hội đồng sẽ yêu cầu chạy trực tiếp công cụ cào tại chỗ một vài trang để kiểm chứng tính xác thực.

3. GIAI ĐOẠN 2: THỰC THI QUY TRÌNH KHAI PHÁ DỮ LIỆU (KDD PIPELINE) TRÊN DỮ LIỆU THỰC TẾ

Sau khi có tệp dữ liệu thô, nhóm áp dụng toàn diện các kỹ thuật đã học qua 6 buổi thực hành trên lớp:

Bước 2.1: Tiền xử lý & Làm sạch dữ liệu tuyển dụng (Data Cleaning)

- **Xử lý mức lương (Salary Normalization):** Dữ liệu lương từ các sàn tuyển dụng rất đa dạng (*"Thoả thuận", "15 - 25 triệu", "1000$ - 2000$", "Up to 30M"*). Nhóm phải viết hàm Regular Expression (Regex) để: tách thành 2 cột `Luong_Min` và `Luong_Max`; quy đổi đồng nhất về đơn vị VNĐ (hoặc USD); và có chiến lược xử lý các tin "Thỏa thuận" (tách riêng hoặc gán nhãn).
- **Chuẩn hóa địa điểm & Số năm kinh nghiệm:** Rút trích tỉnh/thành phố chuẩn (Hà Nội, TP.HCM, Đà Nẵng, Remote) và chuẩn hóa khoảng năm kinh nghiệm thành biến số thực hoặc phân nhóm.
- **Xử lý chuỗi văn bản mô tả (Text Preprocessing & Feature Extraction):** Làm sạch HTML tag, loại bỏ stop words tiếng Việt/Anh, trích xuất danh mục từ khóa kỹ năng công nghệ (Skill Dictionary: Programming Languages, Frameworks, Cloud, Databases, Soft skills) thành dạng ma trận nhị phân (One-Hot) hoặc mảng kỹ năng.

Bước 2.2: Phân tích khám phá & Thống kê mô tả (EDA & Visual Analytics)

- Phân tích phân bố mức lương theo từng cấp bậc (Fresher, Junior, Middle, Senior, Lead).
- Top 15 kỹ năng/công nghệ được săn đón nhiều nhất trong phân khúc thị trường đã chọn.
- So sánh nhu cầu tuyển dụng và mặt bằng đãi ngộ giữa các khu vực địa lý (Hà Nội vs. TP.HCM vs. Đà Nẵng).

Bước 2.3: Gom cụm dữ liệu phân khúc thị trường (Clustering)

- Áp dụng thuật toán **K-Means** hoặc **Hierarchical Clustering** trên không gian kỹ năng và yêu cầu công việc để tìm ra các "chân dung tuyển dụng" đặc thù.
- Biện luận số cụm tối ưu K bằng phương pháp Elbow và Silhouette Score. Đặt tên và định hình chân dung cho từng phân khúc cụ thể (ví dụ: *Cụm Kỹ sư Dữ liệu Cloud-heavy, Cụm Chuyên viên BI & Phân tích Kinh doanh, Cụm Nghiên cứu AI/Học máy*).

Bước 2.4: Khai phá luật kết hợp kỹ năng (Association Rule Mining)

- Áp dụng thuật toán **Apriori** hoặc **FP-Growth** trên tập giỏ kỹ năng yêu cầu trong JD.
- Tìm kiếm các bộ kỹ năng thường được tuyển dụng đồng thời (ví dụ: `{Docker, Kubernetes} ⇒ {Cloud_AWS}` hoặc `{Python, SQL} ⇒ {Machine_Learning}`).
- Lọc luật có giá trị qua các độ đo: `Support`, `Confidence`, `Lift > 1.2` và `Conviction`; phát hiện các luật gây nhiễu/bẫy độ tin cậy.

Bước 2.5: Xây dựng mô hình Dự báo / Phân lớp (Classification / Prediction)

- Xây dựng mô hình phân lớp học có giám sát: Dự đoán mức lương theo khoảng (ví dụ: *Lương Dưới 15M, 15-30M, Trên 30M*) hoặc dự đoán cấp bậc (Junior/Middle/Senior) dựa trên tập kỹ năng và kinh nghiệm.
- So sánh tối thiểu 02 thuật toán: **Decision Tree (kèm cắt tỉa cành ccp_alpha)** và một thuật toán đối sánh (KNN, Random Forest, hoặc Logistic Regression).
- Đánh giá chi tiết bằng Confusion Matrix, Precision, Recall, Macro F1-Score và phân tích các trường hợp dự đoán sai lệch lớn.

4. CẤU TRÚC BÁO CÁO TỔNG KẾT (BÁO CÁO PDF HOÀN CHỈNH)

Báo cáo bài tập lớn phải được trình bày nghiêm túc, chuẩn mực theo cấu trúc học thuật (tối thiểu 15 - 25 trang, không tính phụ lục mã nguồn):

Chương mục	Nội dung trọng tâm cần đạt được	Tiêu chí đánh giá chính
Chương 1: Tổng quan đề tài	Lý do chọn lĩnh vực/ngành nghề; Xác định đối tượng tuyển dụng mục tiêu; Bộ từ khóa tìm kiếm; Tuyên bố các câu hỏi nghiên cứu mà nhóm cần giải đáp.	Tính thực tế, sự hiểu biết về thị trường CNTT, tính rõ ràng của mục tiêu nghiên cứu.
Chương 2: Thu thập & Tiền xử lý dữ liệu	Đặc tả kiến trúc công cụ cào dữ liệu; Thách thức kỹ thuật đã vượt qua (chống chặn IP, lazy loading); Thống kê bộ dữ liệu thô; Chi tiết các bước làm sạch bằng Regex; Kỹ thuật trích xuất đặc trưng văn bản.	Công cụ cào tự viết hoàn chỉnh; Xử lý thành công cột lương/kỹ năng; Không làm méo mó dữ liệu gốc.
Chương 3: Phân tích Khám phá (EDA)	Hệ thống biểu đồ trực quan hóa đa chiều về mức lương, kỹ năng, kinh nghiệm và vùng địa lý; Các phát hiện thống kê đáng chú ý.	Biểu đồ chuyên nghiệp, có chú thích số liệu; Diễn giải sâu sắc, không chỉ mô tả hình vẽ.
Chương 4: Gom cụm & Luật kết hợp	Kết quả gom cụm phân khúc thị trường (Elbow, Silhouette); Bảng phân tích chân dung cụm; Kết quả khai phá tập luật kết hợp kỹ năng (Apriori/FP-Growth, lọc Lift, loại bỏ luật dư thừa).	Phân cụm có ý nghĩa thực tiễn; Luật kết hợp chỉ ra được xu hướng công nghệ thực sự.
Chương 5: Phân lớp & Dự báo	Xây dựng bài toán phân loại lương/cấp bậc; Huấn luyện Cây quyết định và đối sánh đa mô hình; Khảo sát Overfitting; Đánh giá bằng Ma trận nhầm lẫn & F1-Score; Truy vết lỗi sai.	Quy trình Machine Learning chuẩn mực (Tránh rò rỉ dữ liệu); Đánh giá khách quan, trung thực.
Chương 6: Kết luận & Khuyến nghị	Tổng kết các tri thức khai phá được; Đưa ra lời khuyên thực tế cho sinh viên ngành CNTT/Khoa học dữ liệu chuẩn bị hành trang ứng tuyển; Hạn chế của đề tài.	Giá trị ứng dụng thực tiễn cao; Khuyến nghị có số liệu chứng minh rõ ràng.

5. DANH MỤC SẢN PHẨM NỘP BÀI (DELIVERABLES)

- **01 Thư mục mã nguồn Crawler:** Chứa script cào dữ liệu (`scraper.py` hoặc `crawler.ipynb`), tệp `requirements.txt` và hướng dẫn chạy lại công cụ.
- **02 Tệp dữ liệu:** Tệp thô vừa cào về (`raw_data.csv`) và tệp dữ liệu đã qua tiền xử lý, làm sạch hoàn chỉnh (`clean_data.csv`).
- **01 Tệp Jupyter Notebook KDD Pipeline:** Tệp `NhomXX_MiningPipeline.ipynb` chứa toàn bộ quy trình từ EDA, Gom cụm, Luật kết hợp đến Phân lớp (chạy không lỗi từ đầu đến cuối).
- **01 Báo cáo toàn văn:** Tệp tài liệu PDF chuẩn mực (`NhomXX_BaoCao_BaiTapLon.pdf`).
- **01 Slide thuyết trình:** Tệp trình chiếu PowerPoint/PDF (`NhomXX_Slide_BaoCao.pdf`) phục vụ báo cáo bảo vệ ở buổi cuối.

6. KHUNG TIÊU CHÍ ĐÁNH GIÁ & THANG ĐIỂM CHI TIẾT (RUBRIC)

Thành phần đánh giá	Tỷ trọng	Tiêu chí chấm điểm cụ thể
Thu thập & Tiền xử lý dữ liệu (Giai đoạn 1 & 2.1)	**25%**	Tự viết tool cào hoạt động thực tế (10%); Bộ dữ liệu thô đủ lớn > 800 tin (5%); Làm sạch dữ liệu phức tạp: chuẩn hóa lương regex, trích xuất kỹ năng chính xác, xử lý khuyết thiếu bài bản (10%).
Phân tích KDD & Mô hình hóa (Giai đoạn 2.2 - 2.5)	**35%**	EDA đa chiều có chiều sâu (5%); Gom cụm tìm ra chân dung công việc thuyết phục kèm Silhouette/Elbow (10%); Khai phá luật kết hợp kỹ năng, lọc Lift/Conviction sắc bén (10%); Huấn luyện mô hình phân lớp chuẩn, kiểm soát Overfitting, đánh giá F1/Confusion Matrix đầy đủ (10%).
Chất lượng Báo cáo & Tính thực tiễn	**20%**	Báo cáo viết mạch lạc, chuẩn mực khoa học, lập luận logic; Các kết luận và khuyến nghị tuyển dụng mang tính ứng dụng cao cho sinh viên chuẩn bị ra trường.
Thuyết trình & Vấn đáp phản biện (Chống ỷ lại/AI)	**20%**	Trình bày đúng giờ (10 - 12 phút); Trả lời trực tiếp các câu hỏi vấn đáp mổ xẻ mã nguồn, thuật toán và số liệu; Đánh giá mức độ đóng góp thực chất của từng thành viên trong nhóm.

7. QUY CHẾ VẤN ĐÁP BẢO VỆ & CHỐT CHẶN CHỐNG LẠM DỤNG AI

> Nhằm đảm bảo tính công bằng và đánh giá chính xác năng lực thực tế của từng sinh viên:
>
> 1. **Bốc thăm trả lời vấn đáp ngẫu nhiên:** Tại buổi báo cáo cuối cùng, giảng viên sẽ chỉ định ngẫu nhiên bất kỳ thành viên nào trong nhóm trả lời về một phần cụ thể (ví dụ: *Giải thích đoạn code Regex bóc tách lương; Chạy lại hàm tính Silhouette; Giải thích một quy tắc phân nhánh của cây trên tập dữ liệu của nhóm*). Thành viên không hiểu hoặc không trả lời được sẽ bị trừ điểm trực tiếp của cá nhân đó.
> 2. **Biên bản phân công nhiệm vụ chi tiết (Work Breakdown Structure):** Ở trang đầu của báo cáo, nhóm bắt buộc phải có bảng thống kê chi tiết phần việc được giao, tỷ lệ đóng góp (%) và chữ ký xác nhận của từng thành viên. Điểm số cuối cùng của mỗi sinh viên sẽ được nhân với hệ số đóng góp thực tế.
> 3. **Kiểm tra tính nhất quán của mã nguồn:** Bất kỳ đoạn mã nào có tính chất copy nguyên mẫu không phù hợp với cấu trúc dữ liệu của bài toán hoặc không giải thích được cơ chế hoạt động sẽ bị coi là không hợp lệ.

8. QUY ĐỊNH TỔ CHỨC BÁO CÁO & KIỂM TRA TRỰC TIẾP TẠI LỚP (TUẦN SAU)

- **Thời gian & Hình thức:** Báo cáo trực tiếp tại lớp theo lịch học tuần sau. Mỗi nhóm có tối đa **10 – 12 phút thuyết trình** và **5 – 7 phút vấn đáp phản biện** cùng giảng viên.
- **Yêu cầu thiết bị & Môi trường chạy thử:** Nhóm cử đại diện chuẩn bị sẵn máy tính xách tay đã nạp sẵn toàn bộ mã nguồn Crawler, tệp dữ liệu và Notebook KDD Pipeline để sẵn sàng thực hiện thao tác kiểm tra/chạy thử (live demo/code audit) theo yêu cầu ngẫu nhiên của giảng viên.
- **Kiểm tra xác thực dữ liệu cào (Data Audit):** Tệp dữ liệu cào về bắt buộc có cột `URL_Goc` (đường dẫn trực tiếp đến tin tuyển dụng) và thời điểm cào dữ liệu (`Timestamp`). Giảng viên sẽ mở ngẫu nhiên các liên kết để đối soát trực tiếp tính chân thực của dữ liệu so với bài đăng tuyển dụng thực tế.
- **Hạn chót nộp toàn bộ sản phẩm:** Nộp toàn bộ các thành phần (Mã nguồn, Dữ liệu thô & sạch, Notebook, Báo cáo PDF, Slide) lên mục nộp bài tập lớn trên hệ thống LMS trước buổi báo cáo chính thức.